

PRÓXIMA TUTORÍA: Miércoles 25 de marzo a las 12:00

Tutoría 17/03/2026:

- Parece que la mejor configuración es ventana 60 y desplazamiento 15
- Sacar resultados y conclusiones de la importancia por permutación, considerando los 3 modelos de un cada objetivo.
 - o Explorar manualmente uno o dos objetivos para tomar decisiones sobre el número de variables a seleccionar (mediante número fijo o umbral de importancia)
 - o Aplicar el mismo criterio (ej. Seleccionar las 100 mejores variables) a todos los objetivos (seleccionando para cada objetivo sus 100 mejores variables según sus importancias).
 - Cuidado con las importancias negativas.
 - o Comparar en cada caso si es mejor la selección o el completo.
 - o Cualquier otra comparación y forma de seleccionar que ya estes probando.
- Empezar con CNN vs LSTM. Aquí en la preparación de datos nos saltamos el paso de agregación (max, min, mean, std) final. Y nos quedamos, para cada variable con la secuencia completa de 60 valores. La entrada es una matriz tal que $W \times N_{\text{variables}} + \text{órgano}$.
- Ir avanzando con la memoria.

Tutoría 03/03/2026:

- Añadir a informe de resultados métricas que no dependan de umbrales (ap_0, ap_1, roc_auc_0, roc_auc_1, log_loss). No es necesario añadirlas todas.
- Terminar nuevas variables. Tras esto:
 - o Volver a revisar las importancias de variables. ¿permutation importances?
 - o ¿Variar umbrales de decisión?
 - o Se ha visto que ventanas muy grandes son muy pequeñas (no funcionan) Probar con tamaños de ventana cercano a 60 y con más solapamiento (menos offset)

- Observar resultados especialmente en los dos casos más problemáticos: elongacion cervical y rectocele.
- Nota técnica: usar “screen” para lanzar experimentos largos (todos los resultados deben escribirse en ficheros, sobre la marcha, para evitar pérdida).

Tutoría 10/02/2026:

Objetivos 3 y 4: Terminar modelos clásicos (con variables agregadas)

- Explorar como afecta el tamaño de la ventana (60 frames por defecto). Función: `create_agg_df`
- Mejorar la presentación de resultados. Que permita comparar diferentes experimentos y ver lo que mejora o empeora
- Ampliar conjunto de variables:
 - He subido un PDF (TFG_gine_feat_engpdf) con una descripción detallada de todas las variables usadas en el TFG y que se encuentran implementadas en: https://github.com/javiermunrom/pop-detection-ml/blob/main/src/data_preparation/GetFrameData.py
 - Puedes ver un resumen en el apartado 3.6.
 - Creo que podríamos añadir:
 - Distancias euclidianas entre pares de órganos en cada fotograma
 - Algún indicador morfológico como orientación
 - Algún estadístico adicional como skewness
 - Realmente creo que lo más interesante a probar es las distancias euclidianas y el resto (cualquiera de las que aparecen en el PDF) lo dejo a tu criterio, según lo veas interesante y no resulten muy complicadas de calcular. Tampoco te compliques en exceso en este punto.
 - Lee el punto 3.7.1 del documento. Si ves que alguna variable te sale casi constante o con demasiados nulos, no la incluyas.
- Explorar importancia de variables y seleccionar.
 - Hacer algunas pruebas eliminando las variables menos importantes
 - Si hay mejora seleccionamos el conjunto reducido y avanzamos (y si no, seguimos con el conjunto completo).
 - Revisar y usar método importancias por permutación. También explorar las importancias que da el propio modelo.

- Importancias por permutación: https://scikit-learn.org/stable/modules/generated/sklearn.inspection.permutation_importance.html#sklearn.inspection.permutation_importance
- Buscar como obtener importancias de xgboost. Si se complica abandonar.
- En este punto hemos terminado objetivos 3 y 4

Objetivo 5 (LSTM) y 6 (CNN) - (Alternativa 1 la planificación inicial)

- Usar Tensorflow + Keras. Es más sencillo que PyTorch.
- Redes neuronales sobre series temporales. Vamos a probar dos opciones:
 - CNN
 - LSTM
- Te dejo un par de tutoriales, aunque hay muchos. Los temas y técnicas que nos interesan son:
 - Time Series Classification
 - RNN (LSTM) for Time Series Classification
 - CNN for Time Series Classification
- Tutorial de tensorflow:
 - https://www.tensorflow.org/tutorials/structured_data/time_series
 - Me gustan mucho los tutoriales de TF. Lo malo es que es de regresión y no de clasificación, aunque puede servir para coger ideas. Aquí lo que cambia es que lo que se predice son los mismo predictores pero en un estado futuro, mientras que nosotros tenemos una variable objetivo independiente. Hay muchos modelos en el tutorial, en principio solo nos interesa RNN (LSTM) y CNN.
- Ejemplo Keras:
 - http://keras.io/examples/timeseries/timeseries_classification_from_scratch/#build-a-model
 - Aquí usan una CNN para un problema de clasificación.
- En cualquier caso, no te costará encontrar tutoriales sobre el tema. También puedes preguntarle a Gemini/ChatGPT.

1. Tutorial

2. Montar conjunto de datos $N \times W$ donde N son las variables a nivel de frame y W el número de frames de la secuencia.

En estos modelos la entrada no es un vector sino una matriz.

El código hasta la función "compute_frame_features_for_seq" debería ser reutilizable.

3. probar y comparar modelos CNN y LSTM

Si tienes problemas de rendimiento hablar con el profesor para poder usar CUDA+GPU.

Objetivo 7 y 8: Alternativa 2 con LSTM/CNN

22/10/2025: Toma de contacto con el material:

Vamos a hablar de dos conjuntos de variables. Primero trabajaremos con el reducido para ir entrando en el proyecto:

- Conjunto reducido: conjunto de variables usado en el artículo “gine_Ultrasound_Diagnosis_of_Pelvic_Organ_Prolapse_Using_Artificial_Intelligence”
- Conjunto ampliado: usado en el TFG de Javier

Objetivo 1: Toma de contacto con datos y generación de variables (conjunto reducido). La idea es entender los datos que estamos manejando y la metodología en la generación de variables que caracterizan videos (secuencias de frames).

Se ha compartido un proyecto en el servidor de trabajo:

- URL: <https://pybonde.masterds.es>
- Usuario: emivazcru
- Carpeta segments: Por cada vídeo (caso) contiene una carpeta ‘seg’ con las segmentaciones por frame (matrices de probabilidades que devuelve el modelo de segmentación de órganos) y una carpeta ‘clean’ con los fotogramas del video. En principio solo necesitas la carpeta ‘seg’.
- Archivo target_labels_clean.csv: Contiene, para cada caso, el valor de las 7 variables respuesta (patologías presentes en los videos) con las que vamos a trabajar.
- Cuaderno feature_engineering: A partir del material anterior construye un conjunto de datos, calculando el “conjunto reducido” de variables. El resultado es una fila por video. Además, se añaden las 7 respuestas a cada fila. Realmente se ha generado una fila por cada fragmento de video (60 frames por defecto) y órgano, algo de lo que luego hablaremos.

La ejecución del cuaderno genera un csv listo para entrenar y evaluar modelos predictivos. Es importante seleccionar uno de los 7 objetivos y borrar el resto.

Sobre el servidor:

- Si prefieres trabajar con jupyter-lab, añade 'lab' tras la URL, tal que así:
<https://pybonde.masterds.es/user/emivazcru/lab>
- Trabaja siempre con el kernel evc1_314 y si necesitas otro entorno virtual lo comentamos.
- Si necesitas instalar paquetes de Python lo ideal es hacerlo desde una terminal (que se pueden abrir desde jupyter).
 - o 1) Activar entorno: conda activate evc1_314
 - o 2) Instalar paquete: pip install <NOMBRE_PAQUETE>
- Lo he compartido en el servidor ya que son 32GB de datos, si quieres descargarte partes para explorar en local, no hay problema. En ese caso, te recomiendo usar la terminal para comprimir lo que quieras descargar y a continuación, descargar el archivo desde la GUI de Jupyter.

Objetivo 2: Desarrollar un modelo predictivo de enfermedades de suelo pélvico a partir del “conjunto reducido”. La idea es familiarizarse con el flujo de trabajo completo. Una vez completada esta fase, habrás reproducido (aproximadamente) el trabajo realizado en el artículo

“gine_Ultrasound_Diagnosis_of_Pelvic_Organ_Prolapse_Using_Artificial_Intelligence”

Hay algunos detalles importantes del proyecto con los que familiarizarse. Tras el paso anterior, se han generado varias filas por video. A la hora de realizar división train/test y aplicar validación cruzada es muy importante que todas las filas del mismo video estén en la misma partición. Ver:

- https://scikit-learn.org/stable/modules/cross_validation.html#stratifiedgroupkfold
- https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedGroupKFold.html

El esquema habitual suele ser:

1. División inicial en entrenamiento/prueba.
2. Optimización de hiperparámetros sobre conjunto de entrenamiento
3. Evaluar mejor modelo sobre conjunto de prueba

Otros consejos, para ir al grano:

- Pasar rápido a un modelo de altas prestaciones como XGBoost
- Optimizar métricas que no dependan de un umbral de decisión. Principalmente, una de estas dos:
 - o https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html
 - o https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html
- Usar el framework de optimización Optuna:
 - o <https://optuna.readthedocs.io/en/stable/index.html>
- El siguiente código del TFG de Javier sintetiza todas estas ideas:
https://github.com/javiermunrom/pop-detection-ml/blob/main/src/models/cystocele/xgBoost/optuna_xgboost.py

Objetivos 3 y 4: Repetir lo anterior usando el conjunto ampliado.

17-10-2025: Planteamiento proyecto sobre patología de suelo pélvico

Partir del trabajo: Diagnóstico de patología de suelo pélvico:

<https://www.mdpi.com/2077-0383/14/11/3634>

Fase 1: Toma de contacto con datos y proyecto

- Partir de conjunto de datos, reutilizando variables y otros cálculos
- Optimizar algunos modelos y alcanzar resultados similares a los del artículo

Fase 2:

- Entender el efecto del tamaño de ventana
- Probar a muestrear frames

CUDA (posiblemente), a partir de aquí.

Alternativa 1:

- NN que trabaje sobre las características anteriores, pero considerando una secuencia de frames.
 - o LSTM vs CNN
 - o Tamaño de secuencia? muestreo
 - o Secuencia completa?

Alternativa 2:

- NN con secuencias de frames en crudo (máscaras de segmentación)

Alternativa 3:

- Identificar frames característicos. Obtener una muestra de frames diferentes (e.g. un frame que caracterice la primera fase de reposo, otro de máx valsava y otro de segunda fase de reposo)
 - o Global
 - o A nivel de órgano
- NN usando frames característicos

Alternativa 4:

- Lo mismo que “alternativa 3” pero sin usar máscaras de segmentación

Otras preguntas de investigación importantes:

- Las NN abordan de forma natural los problemas multiobjetivo (capturan interacciones).

- Estudiar si una red multiobjetivo aporta una mejora significativa respecto a un solo modelo por objetivo.

PROPUESTA: Segmentación de ecografías y diagnóstico de enfermedad

Referencias sobre ecografía en ginecología: Está separado en dos artículos

- Segmentación: <https://link.springer.com/article/10.1007/s00192-024-05841-0>
- Diagnóstico de patología de suelo pélvico: <https://www.mdpi.com/2077-0383/14/11/3634>

Referencia sobre ecografía en cardiología:

- El artículo principal (PDF adjunto): Video-based AI for beat-to-beat assessment of cardiac function
- Descripción de los datos: <https://echonet.github.io/dynamic/>
- Código: <https://github.com/echonet/dynamic>

El trabajo consiste en familiarizarse con los métodos usados en ambos trabajos y probar variantes. Dos posibles líneas de trabajo son:

- Hacer una red que diagnostica patología de suelo pélvico a partir de segmentos de vídeo completos (que es la metodología usada en 2))
- Aplicar la metodología de ingeniería de variables usada en ginecología para predecir la fracción de eyección en ecocardiograma.

19-09-2025

Decisión final:

- **Ultrasonido sobre ecografías**
- Juegos:
 - Estrategia:
 - **CivRealm**
 - Lux AI Session 1
 - Shooter: VizDoom
- Competición: Buscar más competiciones.

12-09-2025

Reunión para decidir tema del TFG.

Opción 1: Reinforcement Learning sobre Juegos

Explorar:

- Juegos de Kaggle LUX (1, 2 o 3)
- Civilization
- Starcraft (posiblemente demasiado complejo)
- ¿Hay algún Tycoon para RL?

Requisitos:

- Un juego que permita extraer la información del estado en cada momento. Y que permita interactuar (ordenarle acciones a los personajes del juego) con el juego de forma sencilla.
- Opcional: Que el juego se integre con frameworks de entrenamiento de agentes de RL, como Gymnasium.

Opción 2: Juan pensar y proponer algo concreto sobre Meta-Learning+AutoML

Seguimiento

- Llevar un diario actualizado.
- Control de tiempos/tareas
- Opcionalmente, en tareas especialmente llamativas o complejas, llevar el control de los prompts usados en los diferentes LLMs.

Memoria se redacta en LaTeX.