
Ingeniería de variables

Este capítulo describe el proceso completo de transformación de las salidas segmentadas de las ecografías en un conjunto estructurado de variables numéricas. A través de técnicas de umbralización, extracción de características estadísticas, geométricas, texturales y espaciales, y su posterior agregación temporal mediante ventanas deslizantes, se construye un dataset tabular depurado y clínicamente significativo. Este conjunto de datos constituye la base para el entrenamiento de los modelos de clasificación automática desarrollados en los capítulos posteriores.

3.1— Introducción y papel del preprocesamiento

La segmentación automática de las ecografías genera, como salida, una secuencia de mapas de probabilidad que describen la presencia estimada de diferentes órganos pélvicos en cada fotograma. Aunque esta representación resulta adecuada para el análisis visual o la validación clínica, no es directamente utilizable por modelos de aprendizaje automático debido a su alta dimensionalidad, su naturaleza continua y su variabilidad entre fotogramas.

Por ello, el preprocesamiento constituye una fase esencial —y probablemente la más decisiva— del flujo de trabajo. Su propósito es transformar esta salida segmentada en una representación estructurada, depurada y estadísticamente informativa, adecuada para tareas de clasificación supervisada. Esta transformación implica una reducción significativa de la complejidad de los datos y una reorganización de la información en un formato tabular que preserve tanto la trazabilidad clínica como la interpretabilidad computacional.

Este proceso se articula en tres etapas principales:

- La **umbralización** de las matrices de probabilidad, que permite aislar regiones anatómicas consistentes mediante máscaras binarias.
- La **extracción de características** estadísticas, morfológicas, texturales y espaciales a partir de las zonas segmentadas.
- La **estructuración temporal** mediante ventanas deslizantes, que resume la evolución dinámica de los órganos a lo largo de varios fotogramas consecutivos.

El resultado final es un conjunto de *DataFrames*, en los que cada fila representa una ventana temporal asociada a un órgano específico dentro de un vídeo concreto, y cada columna recoge una variable numérica agregada. Este formato compacto y explicativo constituye la base sobre la que se construyen los modelos de clasificación presentados en el capítulo siguiente.

3.2— Estructura de los datos segmentados

El punto de partida lo constituyen las segmentaciones generadas por una red neuronal convolucional previamente entrenada, tal como se detalla en García-Mejido et al. [1]. Estas segmentaciones se aplican directamente sobre las imágenes de las ecografías dinámicas, fotograma a fotograma, y permiten identificar la probabilidad de presencia de ocho órganos pélvicos clave. Dicha probabilidad se representa mediante mapas continuos, también conocidos como matrices de probabilidad, donde cada valor cuantifica el grado de pertenencia de un píxel al órgano correspondiente.

Esta representación probabilística, aunque informativa, no es inmediatamente utilizable para el análisis automático ni para la extracción directa de variables. Por ello, esta sección describe cómo se organiza internamente esta información y cómo se prepara para su posterior transformación en descripciones estructuradas y cuantificables.

3.2.1. Estructura y codificación de las segmentaciones

Cada caso clínico se representa como un vídeo ecográfico dinámico correspondiente a una única paciente, compuesto por aproximadamente 100 *frames*. Cada fotograma incluye la segmentación automática de ocho estructuras anatómicas clave: *ano*, *vejiga*, *músculo elevador del ano*, *pubis*, *recto*, *uretra*, *útero* y *vagina*, generadas por una red neuronal convolucional entrenada para este propósito.

Estas segmentaciones se almacenan como **matrices de probabilidad** de dimensiones 128×128 , cuyos valores pertenecen al rango continuo $[0, 1]$. Por tanto, cada fotograma se codifica como un tensor tridimensional de tamaño $128 \times 128 \times 8$, donde cada canal corresponde a un órgano distinto.

En la Figura 3.1 se muestra un ejemplo visual de estas matrices en forma de mapas de calor, representando un único *frame* de vídeo. Cada recuadro corresponde a un órgano, y el color indica la intensidad de la probabilidad asignada por el modelo a cada píxel. Este tipo de representación resulta útil para visualizar qué zonas son consideradas más relevantes por el modelo en cada estructura anatómica.




Figura 3.1: Mapa de calor de las segmentaciones generadas por la CNN para los distintos órganos en un mismo *frame*, sin aplicar umbral de segmentación. Cada color representa la intensidad de probabilidad para un órgano concreto.

El uso de estas representaciones continuas, en lugar de máscaras binarias directas, permite conservar la incertidumbre asociada a cada predicción. Este enfoque es especialmente valioso cuando se desea realizar análisis probabilísticos o multiclase. No obstante, para la extracción de variables morfológicas y estadísticas más precisas, es necesario convertir estas matrices en regiones definidas, lo cual se aborda en la siguiente sección mediante un proceso de umbralado.

3.2.2. Aplicación de máscaras binarias mediante umbralado (τ_s)

Para extraer regiones anatómicas bien definidas, se aplica un proceso de **umbralización** sobre cada matriz de probabilidad generada por el modelo de segmentación. Este procedimiento consiste en asignar a cada píxel un valor binario (0 o 1) según si su probabilidad supera un umbral de corte predefinido, denotado como τ_s . El resultado es una **máscara binaria** por órgano y por fotograma, que actúa como filtro para la extracción posterior de características morfológicas, espaciales y texturales.

Con el objetivo de evaluar cómo afecta este umbral al proceso de segmentación y al análisis subsiguiente, en este trabajo se han empleado dos valores de referencia: $\tau_s = 0,5$ y $\tau_s = 0,6$.

A continuación, se ilustran ambos casos mediante ejemplos visuales. En la Figura 3.2, se muestra el resultado de aplicar el umbral $\tau_s = 0,5$. Este valor permite segmentaciones más amplias e inclusivas, capturando áreas con menor certeza pero que podrían contener información anatómica relevante. A la izquierda se presenta la matriz de probabilidad con el contorno extraído, y a la derecha, la correspondiente máscara binaria obtenida tras el umbralado:




Figura 3.2: Segmentación de un órgano específico con $\tau_s = 0,5$. A la izquierda se muestra la matriz de probabilidad con el contorno extraído; a la derecha, la correspondiente máscara binarizada.

Por el contrario, al emplear el umbral $\tau_s = 0,6$, como se observa en la Figura 3.3, se obtiene una segmentación más estricta. Solo se conservan aquellas regiones donde la probabilidad de pertenencia es alta, lo que da lugar a máscaras más reducidas pero también más confiables desde el punto de vista del modelo:




Figura 3.3: Segmentación del mismo órgano utilizando $\tau_s = 0,6$. Se observa una región segmentada más precisa pero más reducida.

Este enfoque comparativo mediante distintos umbrales permite analizar el impacto de la segmentación en la calidad de las variables extraídas y, en última instancia, en el rendimiento de los modelos predictivos. En los capítulos siguientes se explorará cómo influye la elección de τ_s en el comportamiento de los clasificadores, proporcionando así una herramienta adicional de ajuste tanto técnico como clínico en el pipeline desarrollado.

3.3– Extracción de características por fotograma

En esta sección se describe el proceso de extracción de variables cuantitativas a partir de cada fotograma (*frame*) del vídeo ecográfico, tras aplicar el umbral de segmentación. Estas variables capturan distintos aspectos del órgano representado: su distribución de intensidades, su forma y posición, y su textura interna. Cada conjunto de variables se genera por órgano y por *frame*, y se almacena en estructuras tabulares para su posterior análisis.

3.3.1. Atributos estadísticos globales

Estas variables se calculan sobre la matriz de probabilidad completa de cada órgano, antes de aplicar cualquier umbral de segmentación. Ofrecen una visión general de la distribución de intensidades estimadas por la CNN para cada píxel del órgano en el fotograma. Este análisis es fundamental para detectar patrones de activación y diferencias globales entre órganos o pacientes.

- **Media (*mean*):** Representa el valor promedio de la matriz. Se calcula como:

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

donde x_i es el valor del píxel i y $N = 128 \times 128 = 16\,384$ es el número total de píxeles.

- **Mediana (*median*):** Valor central de la distribución de intensidades. Es robusta frente a valores extremos y se define como el valor m tal que:

$$P(X \leq m) \geq 0,5 \quad \text{y} \quad P(X \geq m) \geq 0,5$$

donde P es la función de distribución acumulada de los valores de la matriz.

- **Desviación estándar (*std_dev*):** Mide la dispersión de los valores respecto a la media. Se define como:

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

- **Mínimo, máximo y rango:**

$$x_{\min} = \min(x_1, x_2, \dots, x_N) \quad x_{\max} = \max(x_1, x_2, \dots, x_N)$$

$$\text{Rango} = x_{\max} - x_{\min}$$

Estas medidas capturan los valores extremos de la matriz y su amplitud.

- **Asimetría (*skewness*):** Mide la simetría de la distribución. Un valor positivo indica sesgo hacia intensidades altas; un valor negativo, hacia bajas. Se calcula como:

$$\text{Skewness} = \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \mu}{\sigma} \right)^3$$

- **Entropía (*entropy*):** Representa el grado de aleatoriedad o dispersión de los valores de la matriz. Se basa en el histograma de intensidades, discretizado en M bins (por ejemplo, $M = 256$) y se define como:

$$H = - \sum_{j=1}^M p_j \log_2(p_j)$$

donde p_j es la proporción de píxeles que caen en el bin j . Una entropía alta indica mayor variabilidad e incertidumbre en la segmentación.

Este conjunto de métricas proporciona una primera caracterización de cada órgano y permite identificar patrones globales, diferencias entre pacientes o zonas anatómicas, así como detectar valores atípicos o distribuciones anómalas. Estas estadísticas ofrecen una visión general de la intensidad y la variabilidad interna de cada estructura, sirviendo como base para etapas posteriores de análisis.

3.3.2. Atributos sobre la región segmentada del órgano

Una vez aplicada la segmentación mediante umbral (τ_s), se obtiene una máscara binaria en la que solo se conservan los píxeles cuya probabilidad supera dicho umbral. Esta región se interpreta como la zona más activa o más confiable del órgano en términos de segmentación automática, ya que representa los puntos con mayor certeza de pertenencia anatómica.

Sobre esta región filtrada se recalculan todas las métricas estadísticas descritas en el apartado anterior (media, mediana, desviación estándar, asimetría, etc.), pero restringidas únicamente a los valores positivos de la máscara. Esta operación permite comparar la distribución global de intensidades con la de su subconjunto más significativo, proporcionando información sobre la coherencia interna de la segmentación.

En particular, al centrarse en los píxeles con mayor confianza, estas métricas umbralizadas permiten detectar variaciones en la estructura interna del órgano, mejorar la robustez frente al ruido de baja probabilidad y servir como base para las variables que se calculan a partir de estas zonas activas. Además, esta doble perspectiva —global y umbralizada— permite enriquecer el análisis con una visión más focalizada sobre las regiones anatómicas más relevantes.

3.3.3. Propiedades geométricas

Una vez aplicadas las máscaras binarias, se extraen propiedades geométricas clave que describen la localización, el tamaño y la disposición espacial de cada estructura anatómica en el fotograma. Estas métricas permiten detectar desplazamientos, cambios morfológicos y relaciones espaciales entre órganos.

- **Área:** número total de píxeles activados en la máscara binaria, que representa la superficie segmentada del órgano.
- **Rectángulo delimitador (*bounding box*):** es el rectángulo más pequeño que encierra completamente la región segmentada. Se define mediante las coordenadas de sus cuatro bordes: el mínimo y máximo en el eje vertical ($y_{\min}, y_{\max}$) y en el eje horizontal ($x_{\min}, x_{\max}$). Este rectángulo proporciona una estimación rápida de la localización y extensión espacial del órgano segmentado en el fotograma.

- **Centroide:** coordenadas medias (x, y) de todos los píxeles activados. Indica el centro geométrico de la región segmentada.

La Figura 3.4 muestra un ejemplo real en el que se representan los rectángulos delimitadores y centroides de los ocho órganos segmentados en un mismo *frame* ecográfico. Esta visualización permite observar la posición relativa de cada órgano y su distribución espacial en el plano de imagen.




Figura 3.4: Rectángulos delimitadores y centroides de los órganos segmentados en un fotograma ecográfico. Cada rectángulo de color encierra la región activa de un órgano, y los puntos marcan el centro geométrico correspondiente.

3.3.4. Indicadores de forma y estructura anatómica

Las medidas morfológicas describen la forma y geometría de cada órgano segmentado, proporcionando información útil para caracterizar anomalías estructurales o desplazamientos anatómicos. Estas características se calculan a partir de la región umbralizada correspondiente a cada órgano en cada fotograma.

- **Orientación (*orientation*):** Indica el ángulo de inclinación de la elipse equivalente ajustada a la región con respecto al eje horizontal. Se mide en radianes dentro del intervalo $[-\frac{\pi}{2}, \frac{\pi}{2}]$ y se calcula a partir de los momentos de segundo orden. Este valor ayuda a identificar la rotación o el cambio de postura del órgano.




Figura 3.5: Ángulo de orientación de la región segmentada con respecto al eje horizontal. La línea blanca muestra el eje mayor de la elipse ajustada.

- **Eccentricidad (*eccentricity*):** Mide el alargamiento de la forma segmentada. Se define como:

$$\text{Eccentricidad} = \sqrt{1 - \left(\frac{b}{a}\right)^2}$$

donde a y b representan las longitudes del eje mayor y menor, respectivamente. Su valor oscila entre 0 (círculo perfecto) y 1 (línea recta). Una mayor excentricidad puede reflejar una deformación anatómica o elongación del órgano.




Figura 3.6: Elipse ajustada a la región segmentada. El valor de eccentricidad indica cuán alargada está la forma.

- **Perímetro (*perimeter*):** Es la longitud total del contorno de la región segmentada. Se obtiene sumando las distancias entre píxeles consecutivos del borde:

$$\text{Perímetro} = \sum_{(i,j) \in \partial R} d(i,j)$$

donde ∂R es el conjunto de píxeles que forman el borde, y $d(i,j)$ la distancia entre píxeles adyacentes. Un perímetro más complejo puede estar asociado a contornos irregulares o lesiones.




Figura 3.7: Contorno de la región segmentada. Se visualiza la trayectoria que define el perímetro del órgano.

- **Ejes mayor y menor (*major_axis_length*, *minor_axis_length*):** Representan las dimensiones principales de la elipse ajustada a la región segmentada. Son fundamentales para cuantificar la orientación y el tamaño de la estructura.




Figura 3.8: Visualización de los ejes principal y secundario (líneas blanca continua y discontinua) que definen la forma de la elipse equivalente.

- **Solidez (*solidity*):** Relación entre el área real de la región y el área de su envolvente convexa. Se expresa como:

$$\text{Solidez} = \frac{\text{Área de la región}}{\text{Área de la envolvente convexa}}$$

Un valor bajo sugiere concavidades o fragmentación en la región, mientras que un valor próximo a 1 indica una forma convexa y compacta.




Figura 3.9: Contorno de la región (rojo) y su envolvente convexa (blanco). El valor de solidez cuantifica la compacidad de la región.

En caso de que existan múltiples regiones en un mismo fotograma (por ejemplo, debido a artefactos o regiones separadas), se selecciona la de mayor perímetro para asegurar consistencia en las medidas y evitar fragmentos irrelevantes o ruidosos.

3.4— Extracción de características texturales (GLCM)

El análisis de textura constituye una herramienta fundamental para caracterizar patrones de repetición, rugosidad o estructura interna en imágenes biomédicas. En el presente trabajo, se aplican técnicas texturales sobre las regiones segmentadas de los órganos pélvicos, utilizando como base la **matriz de co-ocurrencia de niveles de gris** (*Gray Level Co-occurrence Matrix*, GLCM), introducida por Haralick et al. [15]. Esta matriz permite describir relaciones estadísticas entre píxeles vecinos y extraer métricas que capturan propiedades locales del tejido representado.

3.4.1. Construcción de la matriz de co-ocurrencia

La GLCM se construye a partir de una imagen cuantificada a N niveles de gris, generando una matriz $N \times N$, donde cada entrada $P(i, j)$ representa la frecuencia (normalizada como probabilidad) con la que un píxel con intensidad i aparece junto a otro de intensidad j , bajo una orientación y distancia predefinidas. En este trabajo, se considera la dirección horizontal (0°) y una distancia de $d = 1$, aplicada sobre la máscara binaria del órgano tras aplicar el umbral:

$$P(i, j) = \frac{\text{número de veces que } (i, j) \text{ co-ocurren}}{\text{total de pares considerados}}$$

3.4.2. Contraste, homogeneidad, energía y correlación

A partir de la GLCM se extraen cuatro métricas clásicas que permiten cuantificar aspectos fundamentales de la textura:

- **Contraste (*contrast*):** Mide la intensidad de las diferencias entre píxeles vecinos:

$$\text{Contraste} = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} (i - j)^2 P(i, j)$$

- **Homogeneidad (*homogeneity*):** Evalúa la similitud local, penalizando diferencias entre intensidades:

$$\text{Homogeneidad} = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} \frac{P(i, j)}{1 + |i - j|}$$

- **Energía (*GLCM_energy*):** Refleja la uniformidad de la textura:

$$\text{Energía} = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} P(i, j)^2$$

- **Correlación (*GLCM_correlation*):** Cuantifica la relación lineal entre niveles de gris:

$$\text{Correlación} = \frac{\sum_{i,j} (i - \mu_i)(j - \mu_j) P(i, j)}{\sigma_i \sigma_j}$$

donde μ_i , μ_j y σ_i , σ_j son las medias y desviaciones estándar de filas y columnas.

Estas métricas se computan sobre las regiones segmentadas tras umbralización, enfocando el análisis en las zonas de mayor fiabilidad.

3.4.3. Valor clínico añadido de las texturas

Las variables texturales derivadas de la GLCM aportan una capa adicional de información que no está presente en las métricas geométricas o estadísticas tradicionales. Mientras que estas últimas capturan propiedades globales como el tamaño, la forma o la intensidad media de cada órgano segmentado, las texturales describen cómo varían internamente los niveles de probabilidad a lo largo de su superficie.

Aplicadas sobre los mapas de calor generados por la red de segmentación, estas métricas permiten identificar diferencias internas entre regiones anatómicas que, desde el punto de vista morfológico, podrían parecer idénticas. Por ejemplo, dos órganos con forma, área y posición similares pueden presentar niveles muy distintos de contraste o homogeneidad interna. Esta diferencia puede reflejar configuraciones o patrones que no serían apreciables únicamente mediante el análisis geométrico.

En este trabajo, se incorporan estas características texturales al conjunto de predictores del modelo de clasificación, permitiéndole capturar patrones de comportamiento más complejos y mejorar así su capacidad para detectar casos diferenciados incluso cuando no hay alteraciones visibles en la geometría externa.

3.5— Variables espaciales y relaciones anatómicas

Además de las características morfológicas y texturales individuales, es fundamental analizar las relaciones espaciales entre los distintos órganos segmentados. Esta información ofrece una perspectiva anatómica global que puede ser clave para identificar desplazamientos, colapsos o separaciones anómalas entre estructuras.

3.5.1. Número de contornos detectados

Para cada órgano segmentado se calcula el número total de regiones conectadas presentes en la máscara binaria del fotograma. Esta métrica, denotada como `num_contours`, permite cuantificar la fragmentación de la segmentación anatómica. Un número elevado de contornos puede estar relacionado con errores de segmentación, estructuras irregulares o patologías con disgregación de la forma habitual.




Figura 3.10: Ejemplo de un órgano (vejiga) segmentado con dos contornos distintos en un mismo fotograma. Aunque anatómicamente solo hay una vejiga, la segmentación automática ha generado dos regiones separadas, lo que incrementa el valor de `num_contours`.

3.5.2. Distancias entre centros de órganos

Se calcula la **distancia euclidiana** entre los *centroides* de cada par de órganos presentes en un mismo fotograma. Esta medida permite caracterizar la disposición relativa entre estructuras anatómicas, proporcionando información clave sobre la organización espacial del suelo pélvico. Es particularmente relevante en el estudio de disfunciones que implican descenso o desplazamiento de órganos (e.g. prolapso de vejiga, útero o recto).

La distancia entre dos órganos A y B , con coordenadas de centroide (x_A, y_A) y (x_B, y_B) , se define como:

$$d_{AB} = \sqrt{(x_B - x_A)^2 + (y_B - y_A)^2}$$

Por definición, la distancia entre un órgano y sí mismo es cero: $d_{AA} = 0$.




Figura 3.11: Representación de las distancias euclidianas entre los centroides de los órganos segmentados en un mismo *frame*. Las líneas punteadas indican las conexiones entre pares de órganos y las etiquetas muestran la distancia en píxeles.

Estas distancias sirven como base para el análisis de relaciones anatómicas estables o alteradas, y complementan los indicadores morfológicos tradicionales con una visión relacional de la anatomía ecográfica.

3.6— Resumen de variables generadas

El proceso de ingeniería de variables descrito a lo largo de este capítulo ha permitido transformar las segmentaciones iniciales en un conjunto extenso de predictores numéricos estructurados. A continuación se presenta una síntesis organizada de las variables calculadas, clasificadas según el tipo de información que aportan y la etapa del pipeline en la que se generan:

- **Variables estadísticas globales (pre-umbral):**
 - Media, mediana, desviación estándar, mínimo, máximo, rango.
 - Asimetría (*skewness*) y entropía.
- **Variables estadísticas umbralizadas (post-umbral):**
 - Las mismas métricas anteriores, aplicadas exclusivamente sobre la región activa del órgano.
- **Características geométricas:**
 - Área segmentada, centroide, rectángulo delimitador (*bounding box*).
- **Indicadores morfológicos:**
 - Orientación, excentricidad, perímetro.
 - Longitud de ejes mayor y menor.
 - Solidez (*solidity*).
- **Texturas (GLCM):**

- Contraste, homogeneidad, energía, correlación.

- **Relaciones espaciales:**

- Número de regiones por órgano (`num_contours`).
- Distancias euclidianas entre pares de órganos en cada fotograma.

Este conjunto de variables constituye el punto de partida para construir las representaciones temporales agregadas que finalmente serán utilizadas como entrada en los modelos de clasificación supervisada descritos en el siguiente capítulo.

Cabe señalar que, en etapas posteriores, se realizará una depuración de atributos que permitirá eliminar aquellas variables redundantes, poco informativas o constantes entre muestras, con el objetivo de optimizar la eficiencia del modelo y reducir el sobreajuste.

3.7— Limpieza y estructuración del conjunto de datos

Una vez extraídas todas las variables por fotograma —incluyendo métricas estadísticas, geométricas, texturales y espaciales— es necesario preparar el conjunto de datos para su uso en fases posteriores de análisis, agrupación temporal y clasificación. Esta etapa tiene como objetivo garantizar que los datos estén libres de redundancias, vacíos estructurales o inconsistencias técnicas que puedan comprometer el rendimiento de los modelos predictivos.

Antes de aplicar la transformación temporal mediante ventanas deslizantes, se lleva a cabo una fase sistemática de depuración, imputación y consolidación del conjunto. Además, se generan dos versiones independientes del conjunto de datos, una por cada valor del umbral de segmentación considerado ($\tau_s = 0,5$ y $\tau_s = 0,6$), lo que permite comparar el efecto de dicha variable sobre la calidad de las métricas derivadas.

3.7.1. Depuración de columnas constantes o vacías

Durante el proceso de extracción masiva de características es habitual que algunas columnas presenten valores sin variabilidad o sin información significativa. Estas situaciones pueden deberse, entre otras causas, a:

- La ausencia sistemática de un órgano en determinados vídeos (lo que genera columnas vacías para ciertas métricas).
- Segmentaciones erróneas o fallidas en algunos casos clínicos.
- Métricas que toman el mismo valor en todos los fotogramas (por ejemplo, valores constantes derivados de artefactos).

Por ello, se realiza una inspección exhaustiva del conjunto de datos tras la integración de variables por órgano y por *frame*. Se eliminan automáticamente aquellas columnas que:

- Presentan un único valor constante en todas las muestras (`nunique = 1`).
- Contienen únicamente valores nulos, o más de un 95 % de valores ausentes.

Esta depuración permite:

- Reducir la dimensionalidad del conjunto.
- Minimizar el ruido estadístico en las fases posteriores de agrupación y modelado.
- Favorecer la interpretabilidad de los modelos, al preservar únicamente variables informativas.

3.7.2. Relleno temporal de valores perdidos (forward/backward fill)

En ciertas situaciones, algunas métricas no pueden calcularse correctamente debido a la falta puntual de segmentación válida (por ejemplo, cuando un órgano no se detecta en un *frame* concreto). Para evitar la pérdida de información útil, se aplican técnicas de imputación temporal basadas en la coherencia entre fotogramas consecutivos.

Se emplea un sistema dual de propagación de valores válidos:

- **Forward fill:** rellena cada valor nulo con el último valor válido anterior dentro de la misma serie temporal (órgano/vídeo).
- **Backward fill:** si no existe un valor anterior, se utiliza el siguiente valor válido posterior.

Estas técnicas permiten mantener la continuidad de las variables en el tiempo, especialmente útil en contextos como el clínico, donde se espera una evolución anatómica progresiva y sin cambios abruptos entre fotogramas contiguos. Además, este proceso ayuda a reducir la cantidad de muestras descartadas por valores nulos, maximizando el uso efectivo del conjunto de datos original.

3.7.3. Unificación y generación de los *DataFrames* finales

Tras completar la depuración y el relleno, se consolida toda la información en un único *DataFrame* por valor de umbral. En este proceso se concatenan horizontalmente todas las métricas calculadas para los distintos órganos en cada fotograma, identificando de forma única cada muestra mediante los campos:

- `video_id`: identificador del caso clínico.
- `frame_id`: número de fotograma dentro del vídeo.

Cada fila de este *DataFrame* representa un instante temporal concreto (un *frame*) y contiene las variables numéricas limpias correspondientes a todos los órganos presentes. Los conjuntos obtenidos se almacenan en archivos independientes:

- `Frame-data-50.csv`, correspondiente a $\tau_s = 0,5$.
- `Frame-data-60.csv`, correspondiente a $\tau_s = 0,6$.

Estos ficheros constituyen la base estructurada y homogénea para las siguientes etapas de procesamiento temporal mediante ventanas deslizantes y asignación de etiquetas clínicas por caso.

3.7.4. Ventajas de esta depuración estructurada

El enfoque sistemático de limpieza y estructuración aporta numerosas ventajas:

- Garantiza la integridad y completitud de los datos.
- Elimina columnas redundantes que podrían inducir sobreajuste.
- Asegura la trazabilidad y replicabilidad del análisis, al conservar identificadores explícitos por vídeo y fotograma.
- Facilita el diseño modular del flujo de trabajo, permitiendo generar versiones alternativas del dataset según distintas condiciones (umbrales, filtros, órganos).

Este conjunto depurado y exportado constituye el punto de partida directo para la transformación temporal que se describe en el apartado siguiente.

3.8— Agregación temporal mediante ventanas deslizantes

Tras la limpieza y estructuración del conjunto de datos por fotograma, el siguiente paso consiste en aplicar una transformación temporal que permita capturar la evolución dinámica de los órganos segmentados a lo largo del tiempo. Para ello, se implementa una técnica de **ventanas deslizantes** (*sliding windows*) sobre el `DataFrame` limpio previamente generado.

Este procedimiento agrupa secuencias consecutivas de fotogramas en ventanas de tamaño fijo, desplazándose con un solapamiento determinado. A partir de cada ventana se calcula un nuevo vector de características que resume el comportamiento temporal de cada órgano en ese intervalo.

3.8.1. Motivación y descripción de la técnica

El análisis basado en fotogramas individuales presenta limitaciones importantes en contextos biomédicos como la ecografía dinámica. En primer lugar, la variable de interés en este estudio —la presencia o ausencia de patología— está definida a nivel de vídeo completo, no a nivel de fotograma. Por tanto, no tendría sentido construir modelos que operen directamente sobre instantes aislados, ya que no disponemos de etiquetas clínicas con esa granularidad. Además, los valores extraídos de un único fotograma pueden verse afectados por variaciones fisiológicas transitorias, artefactos de imagen o errores puntuales de segmentación, lo que introduce una elevada variabilidad intra-caso y dificulta la detección de patrones clínicos robustos y consistentes.

Para mitigar estos problemas, se aplica una técnica de **ventanas deslizantes** (*sliding windows*) sobre las secuencias temporales de datos. Este enfoque consiste en agrupar secuencias de fotogramas contiguos en intervalos temporales de tamaño fijo, desplazándose con un paso determinado. Cada uno de estos intervalos o *ventanas* se considera una nueva unidad de análisis, a partir de la cual se calculan estadísticas agregadas que resumen la evolución de las variables en dicho tramo temporal.

Esta transformación permite capturar tendencias dinámicas y patrones estructurales que no son evidentes en un único fotograma, otorgando mayor estabilidad y representatividad a las métricas. Además, al incorporar información temporal, se facilita la detección

de alteraciones progresivas —como desplazamientos de órganos o deformaciones acumulativas— que son características clave en el diagnóstico de patologías del suelo pélvico.

Por otra parte, el uso de solapamiento entre ventanas (*overlap*) incrementa significativamente el número de muestras generadas, lo que resulta especialmente beneficioso en escenarios clínicos con alta desproporción entre clases. Esta estrategia permite incrementar la presencia de casos positivos sin alterar artificialmente la distribución original ni recurrir a técnicas sintéticas de sobremuestreo, preservando así la naturaleza real del conjunto de datos.

3.8.2. Cálculo de estadísticas agregadas por ventana

El procedimiento consiste en recorrer secuencialmente los fotogramas de cada combinación (vídeo, órgano), y agruparlos en bloques temporales fijos mediante una técnica de **ventanas deslizantes** (*sliding windows*). En este trabajo se ha utilizado un tamaño de ventana de 50 fotogramas, desplazada con un paso de 25 (*overlap* del 50 %).

Cada ventana define un intervalo temporal continuo dentro del vídeo, y se considera una nueva unidad de análisis. Para cada una de ellas se calculan estadísticas agregadas a partir de las variables numéricas extraídas previamente por fotograma, con el objetivo de resumir el comportamiento dinámico del órgano durante ese tramo temporal.

Las métricas computadas dentro de cada ventana son:

- **Media** (*mean*): Valor promedio de la variable dentro de la ventana.
- **Máximo** (*max*): Valor más alto registrado en la secuencia.
- **Mínimo** (*min*): Valor más bajo de la secuencia.
- **Rango** (*range*): Diferencia entre el valor máximo y mínimo.
- **Desviación estándar** (*std*): Dispersión de los valores respecto a su media.
- **Asimetría** (*skew*): Grado de sesgo de la distribución temporal de la variable.

Estas operaciones se aplican a todas las variables numéricas del conjunto por *frame*, incluyendo métricas estadísticas, geométricas, morfológicas, texturales (GLCM) y posicionales. Como resultado, cada ventana queda representada por un vector de características que resume su evolución temporal. Este proceso permite transformar el conjunto original, basado en fotogramas individuales, en una representación más estable y adecuada para tareas de clasificación supervisada.

El procedimiento se repite por separado para cada umbral de segmentación utilizado ($\tau_s = 0,5$ y $\tau_s = 0,6$), generando dos versiones independientes de datos agregados que permiten comparar el impacto de dicho parámetro en el análisis final.

3.8.3. Exportación y preparación de conjuntos etiquetados por patología

Una vez finalizado el proceso de agregación temporal mediante ventanas deslizantes, se procede a la preparación completa de los conjuntos de datos para su utilización en la fase de entrenamiento y validación de modelos de clasificación. Este flujo de trabajo se implementa de forma sistemática mediante scripts que automatizan todas las fases, garantizando reproducibilidad y trazabilidad. A continuación se detallan los pasos realizados:

1. Asignación de etiquetas clínicas a las ventanas:

Cada ventana temporal está asociada a un vídeo concreto, pero no contiene por sí misma información clínica. Para vincular estas ventanas con el diagnóstico correspondiente, se utiliza un archivo maestro de etiquetas (`df_target`) que indica, para cada vídeo, la presencia o ausencia de diferentes tipos de prolapso.

El procedimiento consiste en añadir a cada ventana temporal la información clínica asociada al vídeo del que procede. Para ello, se toma la columna correspondiente al diagnóstico (por ejemplo, si el vídeo presenta o no `cystocele`) y se incorpora como una nueva columna a las ventanas que pertenecen a ese vídeo. Así, cada ventana hereda automáticamente la etiqueta clínica del caso al que corresponde.

Las etiquetas están inicialmente en formato booleano (`True/False`), por lo que se convierten en valores enteros binarios (1 para presencia, 0 para ausencia), facilitando su tratamiento posterior en los modelos de clasificación.

Este proceso se repite automáticamente para cada una de las seis variables clínicas que se desean predecir:

`cystocele, cystourethrocele, uterine_prolapse, cervical_elongation,
rectocele y any_prolapse.`

Además, la asignación se realiza por duplicado: una vez para las ventanas generadas con el umbral de segmentación $\tau_s = 0,5$, y otra vez para las correspondientes al umbral $\tau_s = 0,6$, generando así dos versiones completas y paralelas del conjunto etiquetado.

2. Eliminación de vídeos sin información diagnóstica:

Los vídeos que no disponen de diagnóstico confirmado presentan valores ausentes (`NaN`) en las columnas de etiquetas clínicas. Para evitar introducir ruido o ambigüedad en el entrenamiento, se eliminan todas las ventanas correspondientes a esos casos sin información diagnóstica. Este proceso se aplica de forma coherente para cada una de las etiquetas y para ambos umbrales de segmentación.

3. Particionado estratificado con semilla optimizada:

Para cada etiqueta clínica y cada umbral, se busca la mejor partición entre entrenamiento y validación utilizando validación estratificada repetida. Se prueban 600 semillas distintas y se selecciona aquella que consigue una distribución de clases (positivos y negativos) lo más equilibrada posible entre los subconjuntos, manteniendo una proporción del 80 % para entrenamiento y 20 % para validación. Este proceso es especialmente importante en patologías poco frecuentes, ya que evita que el modelo se entrene con conjuntos descompensados.

4. Separación de conjuntos por etiqueta:

Se crean doce conjuntos en total (seis patologías $\times$ dos umbrales), y cada uno se divide en subconjuntos `train` y `test`, según el particionado anterior. Se almacena cada par de subconjuntos en formato binario `.pkl`, con una jerarquía de carpetas por patología y umbral. Ejemplos:

- `data_storage/cystocele/train_test_split.pkl`

- `data_storage/rectoceles/train_test_split_60.pkl`

5. Extracción y estructuración de variables predictoras:

Para cada conjunto de entrenamiento, se realiza la separación en:

- **X** (variables predictoras): todas las métricas agregadas por ventana, excluyendo identificadores (`video`, `frame_start`, `frame_end`) y la variable objetivo.
- **y** (variable objetivo): la etiqueta binaria correspondiente a la patología analizada.
- **groups**: identificador del vídeo, usado para garantizar la independencia entre instancias del mismo caso en la validación cruzada posterior.

6. Exportación final de los conjuntos estructurados:

Los conjuntos (**X**, **y**, **groups**) se guardan en formato `.pkl`, organizados por patología y umbral. Ejemplos:

- `train_data.pkl` → datos con $\tau_s = 0,5$
- `train_data_60.pkl` → datos con $\tau_s = 0,6$

Este pipeline completamente automatizado permite evaluar de manera modular el rendimiento de los modelos para cada tipo de prolapso, explorar el efecto del umbral de segmentación y garantizar consistencia en la estructura de datos empleada. La integración de pasos como la selección óptima de semilla y la separación por grupos fortalece la validez estadística de los resultados obtenidos en la fase de clasificación.

3.8.4. Ventajas frente al análisis individual por frame

El análisis basado exclusivamente en fotogramas individuales presenta una alta sensibilidad al ruido inherente a la imagen médica dinámica. Factores como el movimiento de la sonda ecográfica, artefactos de segmentación o la propia variabilidad fisiológica entre instantes pueden generar oscilaciones significativas en las variables extraídas, dificultando la detección de patrones clínicos consistentes.

El uso de **ventanas deslizantes** proporciona una solución eficaz a esta limitación, ofreciendo diversas ventajas metodológicas y clínicas:

- **Mitigación del ruido puntual:** Agrupar fotogramas en bloques temporales suaviza el efecto de errores aislados o inconsistencias locales, lo que mejora la robustez de las variables derivadas.
- **Captura de trayectorias dinámicas:** Permite modelar procesos progresivos como desplazamientos, elongaciones o cambios morfológicos acumulativos, que son difíciles de detectar en instantes aislados.
- **Estabilidad y coherencia temporal:** La agregación estadística sobre intervalos temporales introduce continuidad en la representación del órgano, eliminando fluctuaciones abruptas y no representativas.

- **Reducción de la variabilidad inter- e intra-paciente:** Al considerar segmentos temporales completos, se obtiene una representación más homogénea y comparativa entre casos, disminuyendo el impacto de diferencias anatómicas individuales o capturas irregulares.

En conjunto, esta técnica dota al modelo de aprendizaje automático de un contexto más rico y fiable, mejor adaptado a la naturaleza dinámica de las ecografías. Además, favorece la identificación de patrones clínicamente sutiles que emergen a lo largo del tiempo y que serían invisibles en un análisis estático por imagen.

3.9— Síntesis y transición hacia la fase de modelado

El conjunto de datos con el que partía este trabajo consistía en secuencias de matrices de probabilidad generadas por un modelo de segmentación automática. Estas matrices, altamente dimensionales y difíciles de explotar directamente, contenían una representación rica pero difusa de la anatomía pélvica.

A lo largo de este capítulo, ese punto de partida ha sido progresivamente transformado en un conjunto estructurado, depurado y orientado al análisis. Cada una de las decisiones tomadas —desde la aplicación de umbrales binarizadores hasta la extracción de características morfológicas, texturales y espaciales— ha estado guiada por un doble criterio: preservar el valor clínico implícito en los datos y hacerlos accesibles a modelos de aprendizaje supervisado.

La aplicación de ventanas deslizantes ha supuesto, además, un cambio conceptual importante: pasar de una lectura imagen a imagen, sujeta al ruido puntual, a una visión más estable y dinámica que representa mejor el comportamiento anatómico a lo largo del tiempo. Esta transformación temporal ha permitido construir un conjunto robusto de ejemplos con contexto temporal integrado, lo que mejora la expresividad de los patrones detectables y la coherencia entre muestras.

En su versión final, el dataset ya no es una simple colección de imágenes médicas procesadas, sino una base de conocimiento multivariable, orientada al diagnóstico automático, en la que cada muestra codifica una secuencia temporal de actividad anatómica. A cada ventana se le ha asociado una etiqueta clínica binaria, garantizando además la independencia entre casos mediante agrupación por paciente.

Esta representación estructurada y validada marca el fin de la fase de ingeniería de variables y habilita el inicio de la fase de modelado automático. En el próximo capítulo se describirá cómo se entrena, valida y compara un conjunto de clasificadores supervisados sobre este dataset, aplicando estrategias de validación cruzada estratificada, optimización de hiperparámetros y ajuste clínico de umbrales de decisión.